

glm5.3-flash

从 958ms 到 39.7ms — 24.1× 推理加速全记录

45 层混合注意力（34 KDA + 11 DSA）· mHC 4 流残差 · kPool 池压缩 · W8A8 量化 — 每一项结构创新在昇腾 910B 上的算子适配、量化盲区修复与 7 级性能优化，全部基于真实实测数据（单机 8 卡 TP8 · w8a8 真实权重）。

TPOT · 每 token 时延

39.7 ms

eager 基线 958.3ms

累计加速比

24.1×

7 级优化阶梯叠加

精度（无回退）

78% / 90%

MMMU_PRO / AIME2026

CH 1 背景与结论 · 8 维差异	CH 2 模型结构 5 处创新	CH 3 W8A8 量化盲区	CH 4 7 级性能阶梯	CH 5 工程化交付
-----------------------	--------------------	-------------------	-----------------	---------------

5 章 34 页 · 一图速览

CH 1

背景与结论

GLM-5.2 → 5.3-flash 的 8 维结构差异 · 45 层混合注意力排布 · 线性注意力科普 (4 页)

CH 2

模型结构创新

KDA 线性注意力 · mHC 4 流残差 · kPool 池压缩 · SwiGLU 钳位 · rope_dim=0 (7 页)

CH 3

W8A8 量化

msmodelslim 四步管线 · QuaRot 旋转盲区 3 处 · 修复后 cos → 1.0 (3 页)

CH 4

性能优化阶梯

958.3 → 39.7ms · 图模式 / fla_npu / 融合算子 / gather 134× / MTP (8 页)

CH 5

工程化交付

TP8 拉起脚本 · 评测数据 · 5 处结构变化 × 问题 × 手段总结 (3 页)

收尾

深读 · 术语 · 文献

KB 同源论文原图深读 · 术语速查 · arXiv 参考文献 (4 页)

★ 阅读动线：技术小白建议顺序读（每章开头有科普）；工程师可直接跳 CH 3 / CH 4 看量化盲区与性能数字。

一页看懂：这次适配交付了什么

口径：单机 8 卡 TP8 · 3.5K 输入 / 1K 输出 · 1 并发 · w8a8 真实权重 · 推理场景单 token 端到端延迟。

TPOT · 每 token 时延

39.7 ms

eager 基线 958.3ms → 7 级优化后 39.7ms，已进入该规模访存下限区间 (~30-40ms)

累计加速比

24.1×

图模式 4.0× → KDA 6.2× → mHC 8.1× → kPool 15.9× → RNE 18.6× → 池 cache 20.4× → MTP 24.1×

吞吐

22.3 tok/s

单并发口径；MTP verify 每步产出 ~2 token

MMMU_PRO

78%

图文多模态精度，量化 + 全部优化后无回退

AIME2026

90%

数学推理精度，量化 + 全部优化后无回退

vs GLM-5.2

成本持平

精度不丢 + 价格不变 = 端到端可交付



小白版 · 把一个 45 层的新模型放到华为 NPU 上跑，开始每个字要等 958 毫秒（一句话卡半分钟）。工程师用 7 招把它压到 39.7 毫秒 — 比眨眼还快，而且答题准确率一分没掉。（上图为 7 级阶梯的 TPOT 毫秒数）

★ 真正的全新工作：KDA、mHC、kPool、SFA 算子对 rope_dim=0 的支持 — 这几项也是后文量化盲区、算子适配与性能优化的来源。

GLM-5.2 → glm5.3-flash：不是「换个算子」

8 个维度的本质变化 — 每一处都触及推理框架的算子 / 量化 / 调度层。右图：结构变化总览（按真实 config 绘制）。

GLM-5.2 → glm5.3-flash · 八维结构变化总览

维度	GLM-5.2	glm5.3-flash
注意力	全程 MLA+DSA	混合：KDA(34) + DSA(11)
残差	标准单流	mHC · 4 流 + Sinkhorn
稀疏索引	lightning_indexer	kPool · 池压缩 ÷4
RoPE 维度	rope=64	rope_dim=0 (SFA 算子适配)
规模	hidden=6144 · 78层 · 256 专家	hidden=4096 · 45层 · 288 专家
SwiGLU	无 clamping	swiglu_limit=10.0 · 4 处覆盖
模态	纯文本	VLM (图文)
复用	—	MoE/MLP/MLA/W8A8 复用自 DSV3.2

图说了什么


glm5.3-flash 相对 5.2 的**真正全新工作**只有 4 项：**KDA 线性注意力（34 层）、mHC 4 流残差、kPool 池压缩索引、rope_dim=0 的 SFA 算子适配**。其余（MoE / MLP / MLA / W8A8）全部复用自 DSV3.2 — 复用决定了适配的主战场在哪。

口径：glm5.3-flash 真实 config.json · hidden=4096 · 45 层 · 288 专家 · qk_rope_head_dim=0

维度	GLM-5.2	glm5.3-flash
注意力	全程 MLA+DSA	混合：KDA(34 层) + DSA(11 层)
残差	标准单流	mHC · 4 流 + Sinkhorn
稀疏索引	lightning_indexer	kPool · 池压缩 ÷4
RoPE 维度	rope=64	rope_dim=0 (SFA 算子适配)
规模	hidden=6144 · 78 层 · 256 专家	hidden=4096 · 45 层 · 288 专家
SwiGLU	无 clamping	swiglu_limit=10.0 · 4 处覆盖

45 层混合注意力 · 34 KDA + 11 DSA

每 4 层一组：前 3 层 KDA（线性注意力）+ 第 4 层 DSA（稀疏全注意力）。第 3/7/11/.../43 层是 DSA = 11 个；其余 34 个 KDA。



图说了什么

上下文 ~8K 是分水岭：8K 以内 DSA 的 KV cache 还小，稀疏全注意力精度更高；超过 8K 后 KDA 的**定长状态**（4.3 MiB/序列，不随长度增长）反超性价比 — 128K 时 DSA cache 涨到 ~2.2GB/序列，KDA 仍是 145 MiB 总量。这就是「混合」的意义：**不是二选一，而是让两种注意力各管自己性价比高的区间。**

口径：glm5.3-flash 真实层级排布 · KDA fp32 状态 4.3 MiB/序列 · DSA ~1.5 KiB/token bf16

小白版 · 想象 45 层是 45 个编辑轮流审稿：34 个是「速读编辑」（KDA，只带一个固定大小的笔记本，越看越薄），11 个是「精读编辑」（DSA，带着整个书库但只翻最相关的 2048 页）。短文章精读编辑更强，长文章速读编辑扛得住 — 所以两种混着排。

三种注意力：O(n²) → O(n) → 稀疏

注意力是 Transformer 的发动机 — 决定「每个 token 该看哪些 token」。glm5.3-flash 把三代技术混在一具模型里。

第 1 代

全注意力 O(n²)

每个 token 跟**所有** token 两两打分。
128K 上下文 = 每 token 算 128K 次关联，算力爆炸。
类比：1000 人开会，每人跟其余 999 人都聊一遍 = 50 万场对话。

第 2 代

KDA 线性注意力 O(n)

维护一个**固定大小**的「滚动总结」状态 **S**，每来 1 个 token 只更新 1 次状态。
128K 上下文 = 只更新 128K 次，**与长度线性**。
类比：不再两两对话，改为每个人在共享笔记本上加一行摘要。

第 3 代

DSA 稀疏索引 O(n · k)

先用轻量 indexer 给所有 token 打分，**只留 top-2048** 做精细注意力；
kPool 再把 4 个 token 合成 1 个打分对象，索引成本 ÷ 4。
类比：图书馆先用目录筛出 2048 本相关的，再逐本精读。

	状态/缓存	随上下文增长	glm5.3-flash 用在哪
全注意力	KV cache 全量	线性涨（无界）	—（未采用）
KDA	S 矩阵定长 4.3 MiB/序列	不涨	34 层 · 长文主力
DSA + kPool	top-2048 稀疏 KV	涨得慢	11 层 · 短文/关键层

★ 同源论文：KDA ← Kimi Linear (arXiv:2510.26692) · DSA ← DeepSeek NSA 系 · kPool ← IndexCache (arXiv:2608.02288)，详见末页参考文献。

02

SECTION 02 · GLM 5.3-flash

模型结构创新

5 处结构改动 — KDA 线性注意力、mHC 多流残差、kPool 稀疏索引、SwiGLU 钳位、rope_dim=0 — 每一处都把「快」做进架构本身。

KDA delta-rule

mHC 4 流 + Sinkhorn

kPool $\div$ 4

SwiGLU clamp=10

rope_dim=0

KDA：用固定大小状态代替 KV cache

KDA（Kimi Delta Attention） 每步原地改写状态矩阵 S。非幂等（与 KV cache 的根本差异）— 这是后文图模式适配的核心难题。

delta-rule 递推 · 每步 O(1) 原地改写

$S = S \times \exp(g)$
 $\delta = (v - S \cdot k) \times \beta$
 $S = S + k \otimes \delta$
 $out = S \cdot q$

① 遗忘：逐 token 逐 head 衰减


② 新息：delta-rule 算更新量

③ 写入：外积写回状态

④ 查询：取状态作为输出

非幂等意味着什么？ KV cache 是「追加」，重放计算结果不变；KDA 的 S 是「原地递推」，前向每跑一遍就推进 N 步 — 图模式 capture 时会把状态推进到错误位置，必须 capture 前 snapshot、capture 后 restore。

★ 关键：S 矩阵 [B, 64, 128, 128] fp32 每步原地改写 — 图模式 capture 前 snapshot、capture 后 restore，让 capture 像没发生过。



(a) Log-decay parameterization. (b) Diagonal-tile computation.

同源证据 · Kimi K3 Fig.3: 左图对数衰减参数化 — Kimi Linear 的 g 无下界（灰线），K3 改用 $g_{min} \cdot \text{Sigmoid}$ 在 -5 处饱和（红线）；右图 chunkwise 计算因此统一为稠密 Tensor Core GEMM，消除「位置对 vs 稠密」混合模式。


★ Moonshot AI, 2026 · Kimi K3 · Fig.3, p.5 · 同源代理 · glm5.3-flash KDA 与 Kimi KDA 同族

小白版 · S 就是那块「滚动笔记本」：每天（每 token）先忘掉一点（ $\times \exp(g)$ ），再把「今天比昨天多了什么」（ δ ）写进去。笔记本页数固定 — 这就是「定长状态」。

HUAWEI

state 槽位与快照机制：让非幂等状态入图

LayerCache 为 KDA 新增 conv/ssm 两槽；SSM $32 \times 128 \times 128$ fp32 = 4MiB/序列定长。图捕获前 snapshot 原始 qkv/gate/ β ，捕获后 restore — 让 capture 像没发生过。



图说了什么

KDA 前端的 5 个组件：**causal conv1d** (kernel=4，短程上下文记忆) → **三个门控** (forget g · input β · output gate) → **delta-rule 递推** → **Q/K L2 归一化 + $1/\sqrt{\text{head_dim}}$ 缩放** (FLA 风格) → **Prefill chunked (chunk=64) / decode recurrent** 双路径。

口径：glm5.3-flash uniinfer 实现 · conv [slots, 3, 3072] fp32 (TP8) · ssm [slots, 8, 128, 128] fp32

LayerCache · 五槽设计（真实代码），KDA 两槽 + DSA 三槽

```
@dataclass
class LayerCache:
    key: torch.Tensor | None = None # DSA: [3227, 128, 1, 512]
    value: torch.Tensor | None = None # DSA: [3227, 128, 1, 0] (rope=0)
    index: torch.Tensor | None = None # DSA: kPool [3227, 128, 1, 257]
    conv: torch.Tensor | None = None # KDA: [slots, 3, 3072] fp32 (TP8)
    ssm: torch.Tensor | None = None # KDA: [slots, 8, 128, 128] fp32

# capture 前 snapshot / capture 后 restore
_snapshot_linear_state(conv_state, ssm_state); graph.replay()
_restore_linear_state(conv_state, ssm_state)
```

KDA conv/ssm 状态 vs 标准 KV cache

两种 cache 活在不同的世界：KV 是「追加 + 幂等」，KDA 是「原地递推 + 非幂等」 — 这就是图模式需要 snapshot/restore 的根本原因。

KDA 状态 vs 标准 KV cache · 6 维对比

	标准 KV cache	KDA conv/ssm 状态
写入语义	追加 (append)	原地递推 (read-modify-write)
幂等性	幂等	非幂等 (前向一遍推进 N 步)
容量驱动	token 数	并发序列数
生命周期	随序列结束	跨整个序列，不可回退
存储精度	bf16	fp32 (递推累积误差放大)
单层大小	~1.5 KiB/token	~4.3 MiB/序列 (定长)

★ KDA 状态 fp32 强制 + 不可 idempotent → 框架需 snapshot/restore + LayerCache 新增 conv/ssm 槽

	标准 KV cache	KDA conv/ssm 状态
写入语义	追加 (append)	原地递推 (read-modify-write)
幂等性	幂等	非幂等 (每跑一遍推进 N 步)
容量驱动	token 数	并发序列数
生命周期	随序列结束释放	跨整个序列，不可回退
存储精度	bf16	fp32 (递推累积误差放大)
单层大小	~1.5 KiB/token	~4.3 MiB/序列 (定长)

Models	SWDE SQD FDA TQA NQ Drop Avg							
<i>Recurrent models</i>								
RetNet	14.0	28.5	7.0	54.4	16.2	17.3	22.9	
HGRN2	8.3	25.3	4.8	51.2	14.2	16.9	20.1	
Mamba	9.8	25.8	3.7	54.3	14.9	17.4	21.0	
Mamba2	19.1	33.6	25.3	61.0	20.8	19.2	29.8	
DeltaNet	17.9	30.9	18.4	53.9	17.3	18.6	26.2	
Gated DeltaNet	25.4	34.8	23.7	60.0	20.0	19.8	30.6	
<i>Attention or hybrid models</i>								
Transformer++	29.5	38.0	52.2	58.3	22.5	21.6	37.0	
Samba	33.0	39.2	50.5	57.7	23.5	20.2	37.3	
Gated DeltaNet-H1	35.6	39.7	52.0	60.1	24.6	22.2	39.0	
Gated DeltaNet-H2	38.2	40.4	50.7	63.3	24.8	23.3	40.1	

Table 4: Accuracy on recall-world retrieval tasks with input truncated to 2K tokens. SQD: SQUADE. TQA: Trivial QA.

同源证据 · Gated DeltaNet Tab.4: GDN (KDA 前身) 在不同 cache 配置下的训练 loss 对比 — 定长状态 + 量化部署的精度代价有公开数据可查。

★ Yang et al., 2024 · arXiv:2412.06464 · Table 4 · 同源代理 · KDA 状态管理方法族

★ 上下文 ~8K 是分水岭：超过 8K 后 KDA 定长状态开始反超性价比 — 128K 时 DSA cache ~2.2GB/序列，KDA 仍 145 MiB/序列。

小白版 · KV cache 像「无限加页的笔记本」 — 文章越长本子越厚；KDA 像「固定 100 页的活页夹」 — 写得再长也只有 100 页，但必须小心：翻错一页就乱（非幂等），所以干活前先拍照（snapshot），干完放回去（restore）。

复用 DSV3.2 MLA，唯一差异 = rope 维度 64 → 0

MLA 的 SFA 算子把 headDim 焊死为 512=kv_lora — 它只认 latent 形态的 K，必须走 absorbed。这反过来决定 cache 布局：value 槽被复用为 rope key 缓存，rope=0 所以零宽 = 0 元素不占显存。

DSA + MLA · absorbed 形态（SFA 算子硬约束）

✗ decompressed 形态（放弃）

Q

K (解压 256)

V (解压 256)

SFA 算子 headDim=512
强制 absorbed → 此路走不通

✓ absorbed 形态（采用）

Q · W_UK

Latent 512

out · W_UV

q 吸收 W_UK → 与 512 维 latent 直算
64× 压缩 · 1 KiB/token · rope=0 零宽 V

cache = [key [N,128,1,512], value [N,128,1,0], index [N,128,1,257]]

★ 唯一差异: qk_rope_head_dim = 64 → 0 | SFA 算子需 tiling 改 kL0Size 96→128

改造点	真实值 / 效果
qk_rope_head_dim	0（DSV3.2 是 64）— 代码显式断言
SFA 算子 tiling	kL0Size 96 → 128
修复	消除 256%96=64 尾部越界崩溃 (error 546)
kernel 内 rope	buffer/offset/copy 全部条件化

cache 布局 + config.json 真实值

索引 cache 实测 (TP8):
k cache [3227, 128, 1, 512] # 3227 block × 128 token
v cache [3227, 128, 1, 0] # rope=0 → 零宽不占显存
indexer cache [3227, 128, 1, 257] # kPool 打包缓存


真实权重 config.json:
"qk_rope_head_dim": 0, "v_head_dim": 256, "qk_nope_head_dim": 256

同源证据 · DeepSeek-V3 Fig.5: MLA 的 absorbed 形态 — K/V 投影矩阵在推理时被吸收进 Q 投影，cache 只存 latent 向量（512 维），这就是 glm5.3-flash DSA 层直接复用的结构。

★ DeepSeek-AI, 2024 · arXiv:2412.19437 · Fig.5, p.13 · 同源代理 · DSA 复用 DSV3.2 MLA


Manifold-constrained Hyper-Connection

用 hc_mult=4 个并行残差流替代标准残差。每层两个 mHC 实例（attn_hc / ffn_hc）。comb 矩阵经 Sinkhorn-Knopp 20 轮行列交替归一化，投影到双随机流形。



打分对象 ÷4：lightning_indexer 的池化升级版

打分对象从「每个 token 的 index key」变成「每 4 token 一组的 pool_key」，选择空间 ÷4。cache 连带变宽：257 = [k(128) + gate_scores(128) + valid(1)]。



gate 只压上界 · up 压双边 · 统一封顶 10

SwiGLU = silu(gate) × up 的乘积没有天然上界（gate=50, up=50 → ≈2500）。一个 outlier 维度就能产生巨值，深网络里一路放大。gate 负方向 silu 自饱和（→0），只压正方向上界；up 两边线性无界，必须两边都压。

SwiGLU clamping · 4 处统一覆盖 swiglu_limit=10.0

dense MLP
Glm5NextTextMLP
✓ clamp(-10,+10)

MoE 288 专家
_apply_gate
✓ clamp(-10,+10)

ViT MLP
Glm5NextVisionMLP
✓ clamp(-10,+10)

ViT patch-merger
Glm5NextVisionPatchMerger
✓ clamp(-10,+10)

```
gate = gate.clamp(max=10)      # silu 饱和, 封顶
up   = up.clamp(min=-10, max=10) # 双边, 封顶
out  = F.silu(gate) * up        # ≈ silu(10) × 10 ≈ 100
```

★ 漏一处就破坏数值一致性 — GLM-5.2 没有，落地时全部 SwiGLU 通路必须带 clamp

位置	钳位策略	原因
gate	只压上界 (+10)	silu 负方向自饱和 →0
up	双边 (±10)	线性无界，两边都会爆
覆盖	4 处统一	dense / 专家 / ViT / patch-merger




Figure 2: Left: During a mid-scale training run, attention logits rapidly exceed 1000, which could lead to potential numerical instabilities and even training divergence. Right: Maximum logits for Kimi K2 with MuonClip and t = 100 over the entire training run. The max logits rapidly increase to the capped value of 100, and only decay to a stable range after approximately 30% of the training steps, demonstrating the effective regulation effect of QK-Clip.

同源证据 · Kimi K2 Fig.2: 训练中 attention logits 会飙到 1000+ — 无钳位时深网络数值发散是真实存在的故障模式，这正是 swiglu_limit=10.0 的动机。

★ Moonshot AI, 2025 · arXiv:2507.20534 · Fig.2, p.4 · 同源代理 · clamp 必要性证据

小白版 · 想象算盘：silu×up 本来没封顶，算错一格结果就上天。clamp=10 就是给每格加盖子 — gate 最高 10、up 在 ±10 之间，再算错也跳不远。

HUAWEI

03

SECTION 03 · GLM 5.3-flash

W8A8 量化方案

msmodelslim 四步 processor 串行 — QuaRot 烘焙 + SmoothQuant + 线性层 int8 + 导出；3 处旋转盲区逐个补旋，cos 从 ≈ 0.017 拉回 1.0。

QuaRot 全局旋转

SmoothQuant 摊平


MLP int8

attn bf16

3 处盲区

msmodelslim · 四步 processor 串行

attention 完全不量化（bf16），只有 MLP 量化成 int8。QuaRot 用全局随机 Hadamard 矩阵 R 把残差流旋转到 $h \cdot R$ 基，摊平离群值，离线烘焙进权重，推理时无运行时旋转。



图说了什么

四步串行：① **QuaRot 烘焙**（全局 Hadamard 旋转写入权重）→ ② **SmoothQuant**（激活离群值摊平到权重）→ ③ **线性层 int8**（MLP 权重 + 激活双 8bit）→ ④ **导出**（w8a8 真实权重）。关键决策：**attention 保持 bf16** — KDA 递推对精度敏感（fp32 状态），量化收益小而风险大。

口径：msmodelslim 实际量化配置 · glm5.3-flash w8a8 权重 · 镜像 quay.io/jd_xllm/xllm-ai

小白版 · 量化 = 把高清照片压成 JPEG 省空间。QuaRot 的「旋转」是先转个角度再压 — 让照片的能量分散开，压完不留明显瑕疵。attention 部分太敏感，干脆不压。

判据：matmul(hidden, W) 且 hidden 来自旋转态 → 必须右旋 W · R

$\sigma(R \cdot h) \neq R \cdot \sigma(h)$ — glm5.3-flash 新增的数据相关门控从旋转残流取输入、输出喂 sigmoid/softmax，若输入投影漏旋，门控就在错误基上算 → **语义偏移**（非量化噪声，是语义错误）。

旋转盲区 · 3 处漏配（QuaRot · R 矩阵）

判据：matmul(hidden, W) 且 hidden 来自旋转态 → 必须右旋 $W \leftarrow W \cdot R$

盲区 1 · KDA 门控

forget_gate.f_a/b_projg_a_proj

问题

34 层 KDA output-gate $\cos \approx 0.017$ （几乎正交）

修复

修复：quarot.py 补 3 条一级右旋

修复后 $\cos = 1.0$

盲区 2 · mHC fn

Parameter[24, 16384]

问题

4 流旋转残差取输入漏旋 · pre 门 $\cos \approx 0.54$

修复

修复：block_diag(R×4) 每流独立消 R

MTP 层无 HC 不配

盲区 3 · indexer compress_gate

index_kpool_compress_gate [128,4096]

问题

校准时 stub=0 隐蔽，真引擎 std=0.17 才出错

修复

修复：model_adapter.py 补右旋 $G \leftarrow G \cdot R$

隐蔽性最强

图说了什么

3 处盲区全是 5.3-flash 的**新增结构**（所以 DSV3.2 时代没暴露过）：

- ① **KDA 门控**：f_a / f_b / g_a_proj 输入维=hidden → 必须右旋（二级投影输入维=head_dim，一级补旋后不旋）
- ② **mHC fn**：4 流独立 → block_diag(R×4) 每流消 R
- ③ **indexer compress_gate**：最隐蔽 — 校准时 stub=0 不触发，真引擎 std=0.17 才出错

口径：quarot.py / model_adapter.py 真实修复 commit · 修复后 cos 相似度 $\approx 0.017 / \approx 0.54 \rightarrow 1.0$

小白版 · 「旋转」像把整个城市地图转了 45° — 所有路牌（权重）都得跟着转。有 3 条路是新修的（KDA 门控 / mHC / kPool indexer），市政忘了给它们换路牌 — 车照老路牌开，就开到错的地方去了。

HUAWEI

quarot.py 补 KDA 门控右旋 + model_adapter.py 补 indexer

一级投影（输入维=hidden）必须右旋；二级投影（输入维=head_dim）一级补旋后不旋。修复后 cos 从 ≈ 0.017 / ≈ 0.54 拉到 1.0。

真实修复 diff · 三处盲区逐个补旋

```
# KDA 门控 · 三条一级右旋 (quarot.py 补)
# f_a / g_a_proj 输入维 = hidden → 必须右旋
forget_gate.f_a_proj.weight.data = forget_gate.f_a_proj.weight.data @ R
forget_gate.f_b_proj.weight.data = forget_gate.f_b_proj.weight.data @ R  # f_b 二级不旋
forget_gate.g_a_proj.weight.data = forget_gate.g_a_proj.weight.data @ R
forget_gate.g_b_proj.weight.data = forget_gate.g_b_proj.weight.data @ R  # g_b 二级不旋

# mHC fn · block_diag(R×4) 每流独立消 R
R4 = torch.block_diag(*[R] * 4)  # 4 流独立消 R
fn_weight.data = fn_weight.data @ R4

# indexer compress_gate · 右旋
index_kpool_compress_gate.weight.data = index_kpool_compress_gate.weight.data @ R
```

盲区 ①

KDA 门控

f_a / f_b / g_a 三条一级右旋。修复前 cos ≈ 0.017 — 几乎完全错误基。

盲区 ②

mHC fn

block_diag(R×4)：4 条流各自消 R，不能共用。修复前 cos ≈ 0.54 。

盲区 ③

indexer compress_gate

校准 stub=0 不触发；真引擎 std=0.17 才暴露 — 最隐蔽。

★ 教训：新增结构 × 量化旋转 = 高危交叉点。任何「输入维 = hidden 的投影」都必须过一遍右旋检查清单。

04

SECTION 04 · GLM 5.3-flash

性能优化阶梯

从 host 阻塞到访存优化到投机解码 — 7 级叠加把 TPOT 从 958.3ms 砍到 39.7ms (24.1×)，MTP 验证接受率 $\approx 80\%$ 。

图模式 aclgraph

KDA fla_npu


mHC 融合 90→180

kPool gather 134×

MTP verify

958.3 → 39.7ms · 24.1× 加速比

每级优化都针对 4 类开销之一：host 调度 / 数据搬运 / 非 AI Core 执行 / 重复计算。第 7 级 MTP 是最后一级，把每 token 期望成本 ÷ 1.8。



★ 口径：单机 8 卡 TP8 · 3.5K 输入 / 1K 输出 · 1 并发 · w8a8 真实权重。该规模访存下限参考 ~30-40ms；39.7ms 已进入这一区间（MTP 后每步产出 ~2 token）。

7 级叠加 · 每一级消除的「无效开销」

逐级实测数据（口径：单机 8 卡 TP8 · 3.5K 输入 / 1K 输出 · 1 并发 · w8a8 真实权重）。

级	优化项	TPOT(ms)	吞吐	累计	机理
基线	eager	958.3	1.04	1×	TTFT 4294ms
1	图模式 aclgraph	237.8	4.14	4.0×	整步录成静态图 · host 清零
2	KDA 优化	155.7	6.23	6.2×	fla_npu 接入 · 状态原位递推
3	mHC 融合算子	119.0	8.17	8.1×	90 串小算子 → 180 融合
4	kPool gather	60.5	15.6	15.9×	fancy idx → F.embedding (134×
5	删 RNE11 位	51.5	17.8	18.6×	bf16 尾数 7 位 < RNE 11 位目标
6	池 cache 物化	46.9	19.8	20.4×	池化确定函数 → O(1) 增量
7	MTP 投机解码	39.7	22.3	24.1×	verify 出 2 token · 接受 ≈80%

最大单级

kPool gather 134×

AI_CPU → AI_VECTOR_CORE：行级取数每层 2.5 → 0.05ms，Index 调用 3354 → 33。

最难工程

MTP lazy-commit

KDA 非幂等状态 × 投机回滚：per-(layer,slot) 暂存 + 跨层批量前进 + lead-trim。


最高性价比

图模式 aclgraph

一级吃掉 4.0×：host 调度开销 ~62% 清零，busy 率 97%。

消除 host 调度开销 · busy 率 97%

eager 下 ~62% 时间 NPU 在等 host（每次 .item() 同步 + Python dispatch + 逐算子 launch）。图模式把整模型前向捕获成一张静态图，逐算子 launch 清零。



图说了什么

左：eager 模式时间线 — host（黄）与 NPU（蓝）交替，气泡巨大；右：aclgraph 静态图 — 整步一次 launch，NPU busy 率 97%。

代价：KDA 非幂等状态必须 snapshot/restore 才能安全 capture（见 CH2 快照机制） — 优化是环环相扣的，不是孤立的 7 招。

口径：TPOT 958.3 → 237.8ms（单级 4.0×） · 静态图捕获 + 状态快照

小白版 · eager 模式像「做一道菜下一次厨房单」：厨师（NPU）大部分时间等服务员（host）下单。图模式 = 把整桌菜单一次性录好，厨师一口气做完 — 这就是 4 倍提速的来源。

delta-rule 主体换成 fla_npu 融合算子

prefill 走 chunk_kda_fwd（5 段融合管线 KdaGateCumsum→Prepare→PostWu→GatedDeltaRuleFwdH→Finalize）；decode 走 recurrent_kda 单 token 递推。**状态原位递推：每层省 2 次全量状态 HBM 往返 × 34 层。**

真实调用契约 · prefill chunked / decode recurrent 双路径

```
# prefill: chunk_kda_fwd 契约 (BSND + 调用方 fp32 l2norm)
q_in = _l2norm(query.float(), dim=-1, eps=1e-6).to(torch.bfloat16)
k_in = _l2norm(key.float(), dim=-1, eps=1e-6).to(torch.bfloat16)
result = chunk_kda_fwd(
    q_in, k_in, v_in, g, b, scale,
    chunk_size=64, layout="BSND",
    initial_state=ssm_state,          # 从 framework ssm 槽取
    output_final_state=True,          # 返回终态, 回写 ssm 槽
    cu_seqlens=cu_seqlens,
    use_gate_in_kernel=False,        # g 已由调用方算好
    state_v_first=True,
)

# decode: recurrent_kda 契约 (TND + 状态原位)
core_attn_out, final_state = recurrent_kda(
    q_tnd, k_tnd, v_tnd, g_tnd, b_tnd,
    initial_state=ssm_state, cu_seqlens=cu_seqlens,
    layout="TND", scale=scale,
    output_final_state=True, inplace_final_state=True,
    use_qk_l2norm_in_kernel=True,
    state_v_first=True,
)
```

省什么

HBM 往返

每层省 2 次全量状态读写 × 34 层 — fp32 状态 4.3MiB/序列，搬运是大头。

契约坑

layout 不一致

prefill=BSND / decode=TND；l2norm 一个在外一个在内 — 接错就静默错。

收益

237.8 → 155.7ms

单级 1.53×（累计 6.2×）。

hc_pre 一个 kernel 完成坍缩全链 · launch ÷2.5

rsqrt (RMSNorm) + linear 投影 + sigmoid 门控 + Sinkhorn 20 轮 + 加权坍缩 → 一次调用产出 (collapsed, post, comb)。hc_post 一个 kernel 完成重组。

真实代码 · hc_pre / hc_post 两融合点

```
# Gln53FlashHyperConnection.forward - 融合路径
if _has_mhc_fused:
    # rsqrt + linear + sigmoid 门控 + Sinkhorn(20 轮) + 加权坍缩
    collapsed, post, comb = kernels.hc_pre(
        hidden_streams,                # [B, S, hc_mult, D]
        self.fn,
        self.scale.float(), self.base.float(), # fp32, 防 load 时被转回 bf16
        hc, self.hc_sinkhorn_iters,
        self.input_norm.variance_epsilon, self.hc_eps,
    )
    return post, comb, collapsed
# (else: 纯 Python 参考实现, 作为 fallback)

# decoder 层内重组合同样走融合 (attn/ffn 两个站点各一次)
hidden_states = kernels.hc_post(hidden_states, residual, post, comb)
```

融合前

90 个串行小算子

每步 rsqrt/linear/sigmoid/Sinkhorn×20/加权 — kernel launch 与 HBM 搬运双杀。

融合后

180 行一个 kernel

中间结果留在片上不落 HBM · launch 数 ÷2.5。


收益

155.7 → 119.0ms

单级 1.31× （累计 8.1×）。

fancy index → flattened gather → F.embedding · 134×

33.5MB → 0.25MB (134×)；Index 调用次数 3354 → 33 (AI_CPU → AI_VECTOR_CORE)；行级取数每层 2.5 → 0.05ms (B=1, T=32768, D=128, rate=4)。



图说了什么

三步演进：

- ① **fancy index**：走 AI_CPU，3354 次调用，33.5MB 中间张量 — host 侧瓶颈
- ② **flattened gather**：索引预先展平，AICore 原生 gather
- ③ **F.embedding**：把 gather 换成 embedding 查表 — 算子映射到 AI_VECTOR_CORE，0.25MB。


这是全部 7 级里单级收益最大的一招（15.9× 累计中的关键一跳）。

口径：B=1, T=32768, D=128, rate=4 · Index 调用 3354 → 33 · TPOT 119.0 → 60.5ms

小白版 · fancy index 像「让前台一张张递照片」（3354 次跑腿）；F.embedding 像「整本相册一次抱走」（33 次）。活儿一样，跑腿的少了 100 倍。


KDA 状态 lazy-commit · 接受率 ≈80% · 39.7ms 最后一跳

per-(layer, slot) 暂存原始 qkv/gate/ β → 跨层批量前进 + lead-trim。spec-verify 入 aclgraph + V3 融合算子 (persistent combined [base|draft] state pool)。



难点	解法
KDA 状态非幂等	draft 前进不写真状态 — lazy-commit，接受才落盘
回滚	per-(layer, slot) 暂存原始 qkv/gate/ β ，跨层批量前进 + lead-trim
verify 开销	spec-verify 入 aclgraph，V3 融合算子
状态池	persistent combined [base draft] state pool
收益	一次替换换一次权重后从 76.3ms 正常化到 39.7ms

小白版 · 普通解码像「写一个字想一次」；MTP 是「先猜 2 个字，让大模型一次验收」— 猜对 80%，等于每步白赚一个 token。难在 KDA 的笔记本不能乱写：猜的时候先写草稿，验收通过才誊正。



同源证据 · DeepSeek-V3 Fig.3: MTP 架构 — 每个位置用共享主干 + 独立输出头预测未来多个 token，训练时多 token 监督、推理时当 draft 头。glm5.3-flash 的 MTP 直接复用此结构。

★ DeepSeek-AI, 2024 · arXiv:2412.19437 · Fig.3, p.10 · 直接同源

★ 接受率 ≈80% · verify 每步出 ~2 token · TPOT 46.9 → 39.7ms（累计 24.1×）— 进入该规模访存下限区间。

05

SECTION 05 · GLM 5.3-flash

工程化交付

镜像 · 拉起脚本 · 评测数据 · 总结 — 让 5.3-flash 真正落到线上推理引擎。

W8A8 + QuaRot

TP8 拉起

MMMU 78%

AIME 90%

成本持平

xllm 服务拉起 · 关键参数

由多机版 3_run_glm_int8_vlm.sh 改写，去掉 EP 与多机，保留图模式 / VLM 后端 / chunked prefill 等关键配置。HCCL_DETERMINISTIC 精度对齐验证时开，生产默认关（更快）。

3_run_glm_int8_vlm.sh · 单机版（真实脚本节选）

```
#!/bin/bash
set -e
# ---- 环境 ----
export PYTORCH_NPU_INSTALL_PATH=/usr/local/libtorch_npu/
export TORCH_DEVICE_BACKEND_AUTOLOAD=0
export PYTORCH_NPU_ALLOC_CONF=expandable_segments:True
source /usr/local/Ascend/ascend-toolkit/set_env.sh
source /usr/local/Ascend/nnal/atb/set_env.sh

# TP8 all-reduce 非确定时逐 forward 有 ulp 噪声，精度对齐验证时必须开；生产默认关
#export HCCL_DETERMINISTIC=true
export HCCL_CONNECT_TIMEOUT=7200
export HCCL_OP_EXPANSION_MODE="AIV"

# ---- 参数（单机 8 卡 TP8） ----
MODEL_PATH=.../glm_next_w8a8_0824
ASCEND_RT_VISIBLE_DEVICES=0,1,2,3,4,5,6,7 \
nohup $XLLM_PATH \
  --model "$MODEL_PATH" --model_id glm5 --port 18000 \
  --nnodes=1 --communication_backend=hccl \
  --max_memory_utilization=0.85 \
  --enable_chunked_prefill=True --max_tokens_per_chunk_for_prefill=8192 \
  --enable_graph=True --model_impl=python \
  --ep_size=1 --backend=vlm --limit_image_per_prompt=8 \
  --max_seqs_per_batch=4 >> log/server.log 2>&1 &
```

★ 镜像：quay.io/jd_xllm/xllm-ai:xllm-dev-a2-arm-cann9-20260801 · 关键开关：enable_graph / chunked_prefill / vlm 后端。

精度不丢 + 价格不变 = 端到端可交付

评测性能数据 · 单机 8 卡 TP8 · w8a8 真实权重 · MTP 开。口径：3.5K 输入 / 1K 输出 · 1 并发。

TPOT

39.7 ms

每 token 端到端延迟 · 访存下限区间内

吞吐

22.3 tok/s

单并发 · MTP verify ~2 token/步

vs eager

24.1×

958.3 → 39.7ms · 7 级阶梯

MMMU_PRO

78%

图文多模态 · 无量化回退

AIME2026

90%

数学推理 · 无量化回退

vs GLM-5.2

持平

精度不丢 · 成本不变

小白版 · 最终成绩单：速度快了 24 倍，考试分数一分没降（MMMU 78% / AIME 90%），部署成本和上一代持平 — 这才叫「交付」，而不是「实验室 demo」。

★ 全部数字来自真实评测 · 精度门：任何优化落地前必须过 40-prompt 子集（必要时 220 全量）再 commit。
★ 代码已合入 `xLLM-AI/xllm @ preview/glm-5.3-flash` (HEAD a6ae154) · 技术与部署镜像、脚本见 jx.huawei.com 内部帖子。

5 处结构变化 × 触发问题 × 解决手段

本文的全部适配工作都源于 glm5.3-flash 相对上一代的几处结构变化。


结构变化	触发的问题	解决手段
KDA 门控线性注意力	旋转盲区 + 状态非幂等入图	quarot.py 补 f_a/b/g_a 一级右旋 · 图模式 snapshot/restore
mHC 多流残差	旋转盲区 + 4 流串流风险	block_diag(R×4) 每流独立消 R · 融合算子降搬运
kPool 稀疏索引	旋转盲区 + fancy idx 走 AI_CPU	model_adapter.py 补右旋 · fancy idx → F.embedding
DSA rope_dim=0	SFA 算子硬编码 rope=64 崩溃	tiling/kernel 改造 · kL0Size 96→128
SwiGLU clamping	新增 clamp 需全覆盖	dense/专家/ViT/patch-merger 4 处统一 clamp

★ 框架侧背景：xllm 组图方式刚从 atb/libtorch 迁移到 PyTorch 组图，图模式、chunked prefill 等加速特性在新架构下需从零适配。最终单机 8 卡 TP8 交付 39.7ms TPOT（24.1×），精度 MMMU_PRO 78% / AIME2026 90%。

小白版 · 一句话：新模型的 5 个「新零件」各自带了一个坑，把坑逐个填平后，速度从「卡到没法用」变成「比眨眼快 10 倍」。

4 篇同源 SOTA · 方法层证据链


glm5.3-flash 的每项结构创新都有公开论文支撑 — 以下 4 张原图 + M3 图文联合解读，全部来自 AICO-Knowledge 知识库。



IndexCache · DSA 稀疏索引加速

GLM-5 + IndexCache 在 10 个 long-context 基准：平均 1.2× E2E speedup 且 HLE/SciCode/MRCR 不掉点 — 稀疏索引「不是丢精度换速度」。glm5.3-flash 的 DSA+kPool 与此同族。


★ Liu et al., 2026 · arXiv:2608.02288 · Fig.1 · 同源代理



Kimi Linear · KDA 全程领先 MLA

Math RL 训练：Kimi Linear@1.4T 在训练集 / MATH500 / AIME2025 三条曲线全程压过 MLA@1.4T（~58-60 vs ~52；~86 vs ~84；~22 vs ~19）— 线性注意力可替代全注意力的实验证据链。


★ Yang et al., 2025 · arXiv:2510.26692 · Fig.6 · 同源代理



mHC · 训练稳定性对比

HC 相对 mHC 的损失差 15k 步后反弹 (~0.005)，HC 梯度范数在 0.10–0.18 剧烈震荡，mHC 从 0.25 单调降到 ~0.05 — 流形约束解决 HC 训练不稳定的直接证据。

★ Xie et al., 2026 · arXiv:2512.24880 · Fig.2 · 直接同源



Megatron-LM · 1F1B 流水线

经典 1F1B pipeline schedule：多卡接力跑 forward/backward，气泡区是「工人等料」的空闲 — glm5.3-flash 训练侧管线与图模式 capture 共享同一类调度思想。

★ Narayanan et al., 2021 · arXiv:2104.04473 · Fig.4 · 方法同源

★ 同源代理声明：glm5.3-flash 为闭源模型，架构原图不可公开获取 — 以上用同族论文原图作方法层证据，工程数据（时延/精度）全部为 uniinfer 实测。

术语速查 · 24 项

KDA Kimi Delta Attention · 递推式线性注意力	DSA DeepSeek Sparse Attention · top-k 稀疏索引	MLA Multi-head Latent Attention · KV 低秩吸收	kPool 4-to-1 池化 · 索引打分对象 ÷4
mHC manifold-constrained Hyper Connections · 4 流残差	Sinkhorn 行列交替归一化 → 双随机流形投影	delta-rule $\delta=(v-S \cdot k) \times \beta$ · KDA 状态更新规则	非幂等 前向每跑一遍状态推进 N 步 · 图模式大敌
snapshot/restore capture 前快照、后恢复 · 让非幂等入图	rope_dim=0 SFA 算子适配 · v cache 零宽不占显存	SwiGLU clamp $gate \leq 10$ · $up \pm 10$ · 防数值发散	QuaRot 全局 Hadamard 旋转 · 离线烘焙进权重
旋转盲区 漏右旋 $W \cdot R$ 的投影 → 语义错误	SmoothQuant 激活离群值摊平到权重	W8A8 权重 8bit + 激活 8bit 量化	aclgraph 整步前向录成静态图 · host 清零
fla_npu KDA 融合算子库 · chunk/recurrent 双路径	hc_pre/hc_post mHC 坍缩/重组融合 kernel	F.embedding gather 查表化 · kPool 134× 关键	MTP Multi-Token Prediction · 投机解码 draft
lazy-commit draft 不写状态，接受才落盘	TPOT Time Per Output Token · 每 token 时延	TTFT Time To First Token · 首 token 时延	同源代理 闭源模型借同族公开论文作方法证据

★ 完整定义见各章正文；标注「同源代理」处表示 glm5.3-flash 闭源、借用公开同族论文证据。

参考文献 · 按主题分组

glm5.3-flash 为闭源模型（内部 wiki 图床不可达）。以下公开同族论文构成方法层证据链，arXiv ID 均经知识库逐篇验证。

A · 线性注意力 / KDA 同族

[1]

Kimi Linear: An Expressive, Efficient Attention Architecture

· arXiv:2510.26692

· Yang et al., 2025

KDA 架构 · lower-bounded decay · RL 全程压过 MLA — ch1/ch2-kda 方法源

[2]

Kimi K3: Open Frontier Intelligence

· Kimi K3 report

· Moonshot AI, 2026

chunkwise KDA 对角块统一为稠密 GEMM · 衰减下界 — ch2-kda 同源证据

[3]

Gated Delta Networks: Improving Mamba2 with Delta Rule

· arXiv:2412.06464

· Yang et al., 2024

delta-rule 递推的 KDA 前身 · 状态管理对比 — ch2-kda-state 方法源

B · 稀疏注意力 / 索引

[4]

IndexCache: Accelerating Sparse Attention via Cross-Layer Index Reuse

· arXiv:2608.02288

· Liu et al., 2026

lightning indexer 跨层复用 · $1.2\times$ E2E — ch1/kPool 同源证据

[5]

DeepSeek-V3 Technical Report

· arXiv:2412.19437

· DeepSeek-AI, 2024

MLA absorbed 形态 (Fig.5) · MTP 架构 (Fig.3) · DualPipe — ch2-dsa / ch4-mtp 直接同源

C · 多流残差

[6]

HC: Manifold-Constrained Hyper Connections

· arXiv:2512.24880

· Xie et al., 2026

mHC 结构 + Sinkhorn 投影 + 训练稳定性证据 — ch2-mhc 直接同源

[7]

Hyper-Connections

· arXiv (ByteDance)

· Zhu et al., 2024

HC 无约束前身 · mHC 的改进对象 — ch2-mhc 背景

D · 训练 / 量化 / 数值稳定

[8]

Efficient Large-Scale LM Training on GPU Clusters (Megatron-LM)

· arXiv:2104.04473

· Narayanan et al., 2021

1F1B 流水线调度 — ch3 训练侧方法源

[9]

Kimi K2: Open Agentic Intelligence

· arXiv:2507.20534

· Moonshot AI, 2025

attention logits >1000 数值爆炸图 — ch2-swiglu clamp 动机证据

[10]

QuaRot: Outlier-Free 4-Bit Inference

· arXiv:2404.00456

· Ashkboos et al., 2024

Hadamard 旋转量化 — ch3 量化管线方法源

E · 官方交付（一手出处）

[11]

GLM5.3-Flash 昇腾 NPU + xllm 0day 适配与 SOTA 性能调优

· 官方交付说明

· xLLM-AI/xllm @ preview/glm-5.3-flash

· 交付与服务军团, 2026

单机 8 卡 TP8 稳定部署 · Decode 22.3 tok/s · TPOT 39.7ms · 较基线 $24\times$ · MMMU_PRO 78% · AIME2026 90% — 本 deck 全部工程数据的官方口径

[12]

技术分析与部署镜像、脚本（内部帖子）

· jx.huawei.com sc-camel-post-id=45aa14453ea649c9a5fb1f01ddf45161

· 交付与服务军团, 2026

线性注意力状态管理 · 旋转量化精度 · KDA 与 Index Key Pool 性能瓶颈 — 本 deck ch2/ch3/ch4 的技术分析原文

Thank you.

把数字世界带入每个人、每个家庭、每个组织，构建万物互联的智能世界。

Bring digital to every person, home, and organization for a fully connected, intelligent world.

glm5.3-flash 昇腾 uniinfer 适配实录 • 2026/08

全部性能 / 精度数字为真实实测 • 同源论文经 AICO-Knowledge 逐篇验证

Copyright © 2026 AICO • 供内部技术汇报使用